

UNIVERSIDADE SÃO JUDAS TADEU

Ciências da Computação

Bruno Silva Cândido Oliveira

Carlos Diego Ticona Arias

Gabriel Argoso dos Reis

Gabriel Seiji Santos Pereira

Juan Brito Grangeiro

Ygor Wladimir Vilaça Carmona Junior

William Fernandes Trindade

Projeto Armageddon

São Paulo

2025

RESUMO: PREDIÇÃO DE PREÇO VEÍCULOS USADOS

Neste projeto, aplicamos quatro técnicas de regressão — Regressão Linear Múltipla, KNN (K-Nearest Neighbors), SVM (Support Vector Machine) e Árvore de Decisão — para prever o preço de veículos usados com base em atributos como potência do motor, idade, quilometragem e popularidade da marca.

Utilizamos o “Automotive Price Prediction Dataset”, que contém 1.000.000 de registros sintéticos gerados de forma programática, refletindo correlações realistas entre as variáveis. O conjunto considera fatores como depreciação pela idade, desgaste pelo uso (quilometragem), potência do motor e valor da marca, tornando-o adequado para treinar e comparar modelos de previsão de preços.

Dataset: <https://www.kaggle.com/datasets/metawave/vehicle-price-prediction/data>

RESUMO: FRAUDE DE CARTÃO DE CRÉDITO

Neste projeto, aplicamos duas técnicas de classificação — Redes Neurais e Naive Bayes — para identificar transações fraudulentas em operações de cartão de crédito. O objetivo é desenvolver modelos capazes de distinguir, de forma automática e eficiente, transações legítimas das potencialmente fraudulentas, com base em padrões e características numéricas e categóricas extraídas dos dados.

Utilizamos o “Credit Card Fraud Detection Dataset”, que contém registros de transações reais realizadas por clientes, onde apenas uma pequena fração corresponde a fraudes. O conjunto de dados apresenta alto desbalanceamento, o que torna o problema mais desafiador e relevante para aplicações práticas. Foram consideradas variáveis como valor da transação, horário, e atributos transformados por técnicas de redução de dimensionalidade, tornando-o adequado para o treinamento e avaliação de modelos preditivos de detecção de fraudes.

Dataset: <https://www.kaggle.com/datasets/pratyushpuri/payment-card-fraud-detection-with-ml-models-2025>

OBJETIVO: PREDIÇÃO DE PREÇO VEÍCULOS USADOS

O objetivo principal foi identificar quais modelos apresentaram melhor desempenho e resultado final dentre as aplicações de regressão e classificação, comparando entre eles e identificando qual se destaca.

OBJETIVO: FRAUDE DE CARTÃO DE CRÉDITO

O objetivo principal foi avaliar o desempenho dos algoritmos de Redes Neurais e Naive Bayes na identificação de fraudes em transações financeiras, comparando suas taxas de acerto, precisão, recall e F1-score. A comparação entre as duas abordagens permitiu identificar qual modelo apresentou melhor equilíbrio entre sensibilidade e precisão na detecção de atividades fraudulentas.

Dataset de Predição de Preço de Veículos Usados: Técnicas de Regressão

1. Regressão Linear Múltipla

A Regressão Linear Múltipla é o modelo mais simples e assume uma relação linear entre as variáveis independentes e o preço. Ela tenta ajustar uma equação na forma: $\text{preço} = b_0 + b_1 \cdot \text{ano} + b_2 \cdot \text{quilometragem} + b_3 \cdot \text{potência} + \dots$

- Vantagens: fácil de entender e rápida para treinar.
- Desvantagens: não lida bem com relações complexas entre as variáveis.
- Resultado obtido: MAE = 3249 (15,96%)

2. KNN (K-Nearest Neighbors)

O modelo KNN faz previsões com base nos vizinhos mais próximos. Para prever o preço de um carro, ele considera os 5 carros mais semelhantes e calcula a média dos preços.

- Vantagens: simples e capaz de capturar relações não lineares.
- Desvantagens: sensível à escala dos dados e mais lento em grandes conjuntos de dados.
- Resultado obtido: MAE = 2823 (13,89%)

3. Árvore de Decisão

A Árvore de Decisão divide os dados em grupos menores com base em perguntas do tipo 'sim ou não'. Por exemplo: 'A idade do veículo é menor que 3 anos?' ou 'A potência do motor é maior que 200 HP?'. Cada resposta leva o modelo a um grupo diferente até chegar a uma previsão final de preço.

- Vantagens: entende relações complexas e não precisa de normalização dos dados.
- Desvantagens: pode sofrer com overfitting se não for bem ajustada.
- Resultado obtido: MAE = R\$ 2.066,00 (10,17%)

4. SVM (Support Vector Machine)

O modelo SVM busca encontrar um hiperplano que melhor separe ou ajuste os dados, maximizando a margem entre os pontos e a linha de regressão. No caso da regressão, ele tenta ajustar uma linha (ou plano, no caso de múltiplas variáveis) de forma que a maioria dos pontos fique dentro de uma faixa de tolerância definida.

- Vantagens: pode capturar relações não lineares entre as variáveis por meio do uso de kernels; é robusto a outliers quando bem configurado.
- Desvantagens: exige ajuste cuidadoso dos parâmetros (como o kernel e o valor de C) e pode ser computacionalmente mais pesado em grandes bases de dados.
- Resultado obtido: MAE = R\$ 10.152,00 (aproximadamente 50%)

Comparação dos Resultados

Os resultados mostram que a Árvore de Decisão apresentou o menor erro médio absoluto (MAE), indicando maior precisão nas previsões. O resumo é o seguinte:

Modelo	MAE	Erro Percentual (%)
SVM	R\$ 10.152,00	50,03%
Regressão Linear Múltipla	R\$ 3.249,00	15,96%
KNN	R\$ 2.823,00	13,89%
Árvore de Decisão	R\$ 2.066,00	10,17%

Dataset de Fraudes de Cartão de Crédito: Técnicas de Classificação

1. Redes Neurais

As Redes Neurais Artificiais (RNA) são inspiradas no funcionamento do cérebro humano e compostas por camadas de neurônios interconectados. Cada neurônio processa entradas, aplica pesos e ativações não lineares, ajustando seus parâmetros durante o treinamento para minimizar o erro de previsão.

Na detecção de fraude de cartão de crédito, as Redes Neurais analisam padrões complexos de comportamento das transações — como valor, horário, localização e frequência — para identificar anomalias que indicam fraudes. Elas conseguem aprender relações sutis e não lineares entre as variáveis, sendo eficazes para distinguir transações legítimas das fraudulentas.

- Vantagens:

- Alta capacidade de generalização e detecção de padrões complexos.
- Funciona bem com grandes volumes de dados.
- Adaptável a diferentes tipos de atributos e distribuições.

- Desvantagens:

- Requer alto poder computacional e tempo de treinamento.
- Difícil interpretação dos resultados (modelo “caixa-preta”).
- Pode sofrer overfitting (falha ao aprender novos dados) se não for bem regularizada

- Resultado obtido: Alta precisão (99,3%). Erro percentual de (0,7%)

2. Naive Bayes

O algoritmo Naive Bayes é baseado no Teorema de Bayes, que calcula a probabilidade de um evento ocorrer com base em evidências anteriores. É chamado de “ingênuo” porque assume independência entre as variáveis — ou seja, considera que cada atributo influencia o resultado de forma isolada.

Na detecção de fraudes, o Naive Bayes estima a probabilidade de uma transação ser fraudulenta comparando características como valor, frequência e horário de uso, com base nas probabilidades observadas em transações anteriores.

- Vantagens:

- Simples de implementar e muito rápido para treinar.
- Bom desempenho em dados de alta dimensionalidade.
- Efetivo mesmo com poucos dados de treino.

- Desvantagens:

- Suposição de independência entre atributos raramente é verdadeira (ou seja, a ocorrência ou o valor de um atributo não é influenciado pela ocorrência ou pelo valor de outro atributo).
- Pode ter desempenho inferior em problemas com relações complexas entre variáveis.
- Sensível a atributos altamente correlacionados.

- Resultado obtido: Precisão de 94,8%, apesar de mais rápido, apresenta maiores taxas de falsos positivos, ou seja: indica a existência de uma condição quando ela, na realidade, não está presente.

Comparação dos Resultados

Os resultados mostram que a

Modelo	Métrica	Erro Percentual (%)
Naive Bayes	Precisão de: 94,8%	5,2%
Redes Neurais	Precisão de 99,3%	0,7%

CONCLUSÃO: DATASET PREDIÇÃO DE PREÇO VEÍCULOS USADOS

Com base na comparação dos resultados, concluímos que o modelo de Árvore de Decisão é o mais adequado para o problema em questão. Ele apresentou o menor erro médio (MAE) e melhor capacidade de capturar relações complexas entre as variáveis do conjunto de dados.

Portanto, adotamos a **Árvore de Decisão** como o modelo final para a predição de preços de veículos.

CONCLUSÃO: FRAUDE DE CARTÃO DE CRÉDITO

Com base na comparação dos resultados, concluímos que o modelo de Redes Neurais é o mais adequado para o problema de detecção de fraude de cartão de crédito, devido à sua capacidade de aprender padrões complexos e obter alta precisão, mesmo em um cenário com forte desbalanceamento entre classes.

O Naive Bayes, embora apresente menor desempenho, destaca-se pela simplicidade, velocidade de treinamento e interpretabilidade, podendo ser utilizado como modelo inicial ou auxiliar em sistemas híbridos de detecção de fraude.